

Relatório Final – Semáforo Inteligente

Aluno: Liedson Augusto Maciel Costa

Resumo da proposta do sistema

O projeto **Semáforo Inteligente** teve como objetivo desenvolver um sistema baseado em rede neural capaz de receber a configuração de veículos em um cruzamento e devolver o tempo de sinal verde mais adequado para otimizar o fluxo de tráfego.

A proposta buscou criar um agente inteligente capaz de reduzir o tempo médio de espera dos veículos por meio de um ciclo semafórico dinâmico, adaptado às condições reais de tráfego. Para isso, foram utilizadas simulações que representavam diferentes cenários de fluxo, envolvendo múltiplos tipos de veículos com características próprias, como aceleração e tempo de reação após o sinal abrir.

Papéis dos agentes

O sistema contou com apenas **um agente**:

- **Semáforo Inteligente**: responsável por analisar a configuração dos veículos parados (ordenados pela proximidade ao semáforo) e calcular o tempo de verde ideal para liberar o tráfego. Esse agente recebe como entrada a lista de veículos detectados, consultava o conhecimento adquirido por meio do treinamento de rede neural e retornava o tempo estimado para esvaziar a fila. Não houve integração direta com um semáforo simulado no SUMO, pois o foco foi a criação e teste do modelo preditivo.
-

O que deu certo

Foi desenvolvido com sucesso um **simulador de tráfego** no SUMO, capaz de gerar e armazenar diferentes configurações de veículos e os respectivos tempos necessários para esvaziar as filas. Esse simulador permitiu criar uma base de dados robusta, utilizada para treinar e validar a rede neural. O processo de geração de dados incluiu variações no fluxo e na composição de veículos, o que garantiu diversidade nos cenários para o treinamento do modelo.

O que deu errado

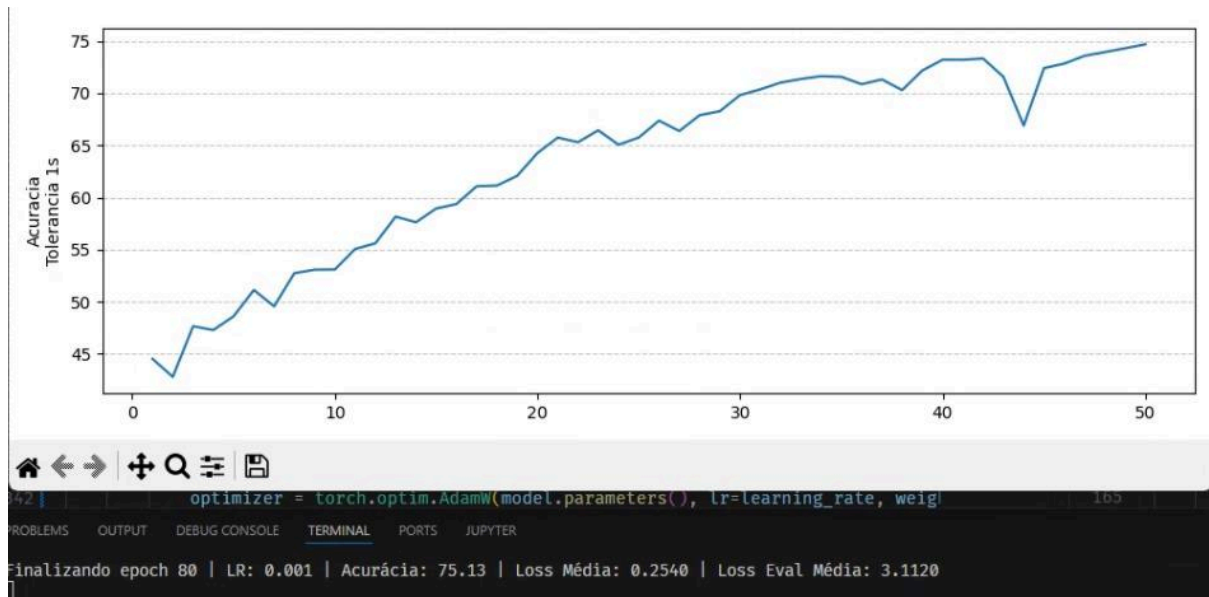
Apesar dos avanços, o modelo não atingiu um nível de acurácia considerado satisfatório para a aplicação prática. Foram realizados testes com diferentes tolerâncias de erro entre o tempo predito e o real:

- **0 segundos** de tolerância: 66% de acurácia
- **1 segundo** de tolerância: 75% de acurácia
- **2 segundos** de tolerância: 80% de acurácia
- **3 segundos** de tolerância: 84% de acurácia

Modelo usado para esses parâmetros:

```
SemaforoInteligente(  
  (camadas): Sequential(  
    (0): Linear(in_features=23, out_features=19550, bias=True)  
    (1): ReLU()  
    (2): Linear(in_features=19550, out_features=2932, bias=True)  
    (3): ReLU()  
    (4): Linear(in_features=2932, out_features=439, bias=True)  
    (5): ReLU()  
    (6): Linear(in_features=439, out_features=65, bias=True)  
    (7): ReLU()  
    (8): Linear(in_features=65, out_features=49, bias=True)  
  )  
)
```

Gráfico de aprendizado:



Os resultados indicaram que o modelo conseguiu aprender padrões, mas apresentava limitações na generalização para cenários mais complexos. Entre os principais desafios, destacam-se:

- Ajuste inadequado de hiperparâmetros.
- Limitações na forma de representação das configurações de veículos.
- Falta de integração com um semáforo funcional para validação em ambiente simulado completo.

O que faria diferente

Se o projeto fosse reiniciado hoje, seriam adotadas as seguintes mudanças:

- Estudo e implementação de novas formas de representar e simular as configurações de veículos, para melhorar a qualidade dos dados de entrada.
- Exploração de diferentes arquiteturas e tecnologias de redes neurais, além de técnicas de regularização e otimização.
- Ajuste mais aprofundado de hiperparâmetros.
- Integração direta do agente com um semáforo simulado no SUMO, permitindo testes mais realistas e feedback em tempo real.

Aprendizados sobre sistemas multiagentes

Durante o desenvolvimento do projeto, ficou evidente que sistemas multiagentes exigem uma definição clara dos papéis e responsabilidades de cada agente, bem como protocolos eficientes para troca de informações.

No caso deste projeto, mesmo com apenas um agente principal, foi possível compreender que:

- O desempenho do agente depende diretamente da qualidade e diversidade das informações que recebe.
- A coordenação entre agentes (no caso de haver mais de um) poderia permitir decisões mais rápidas e robustas.
- Em sistemas reais, agentes não operam isoladamente: sensores, controladores e bancos de dados também podem ser considerados agentes de apoio, e a integração entre eles é essencial para atingir os objetivos do sistema.